一个永不关机的大脑：二值神经元、一条局部学习规则、先天连接、只通过肌肉说话

架构、理论，以及在一门自创逻辑语言上的测试

李秩文（Zhiwen Li，ORCID 0009-0005-8289-6393），独立研究者
2026 年 11 月，技术报告第 1 版
代码、报告和所有失败的结果：https://github.com/leeR1ven/concept-brain（MIT 许可证）
永久存档：Zenodo 10.5281/zenodo.24084045（所有版本；v1.0 为 10.5281/zenodo.24084046），以及 Software Heritage

英文版：concept-brain.pdf（源文件 concept-brain.tex）。两版内容相同。

摘要

我们介绍 concept-brain：一个只活一辈子的人工大脑研究原型。它从不重置、从不冻结、从不离线训练。它只由以下几样组成：

- 出生时由同一个生成器（立体、局部、随机）接好的二值神经元；
- 一条带凹形增长的局部赫布学习规则，加一个全脑统一降权；
- 只通过模拟肌肉输出。

各感觉区把特征神经元一对一地复制到多层前额叶的第一层（“副本”）。前额叶最后一层预测下一刻的输入；第一层被内部点亮的副本就是“想法”；说话就是把这个预测送回肌肉。奖励只是工具：做对了加强、做错了削弱最近一两秒里带出动作的连接。

本文给出：

1. 写成规则的架构；
2. 理论：在写明的条件下，最后一层的赫布读出就是自回归语言模型的读出，并附信噪比和时间差分析；
3. 按规则搭出的大脑的实测；
4. 在一门 13 个词的自创逻辑语言上的测试。选它，是因为它小、精确、可复现。

在这门语言里，大脑只听别人之间的对话，没有任何奖惩，就学会了：

- 听 20 段对话后，在“T ?”之后预期正确的答案词；
- 只要一句话按它工作记忆窗口的节奏说出来，“NOT T ?”这类句子听 1–2 遍就学会。

加上手动接好的“词 ↔ 肌肉”连接和先天刹车后，它会轮到自己时作答，不抢别人的话。我们也列出了还做不到的事：语言的大部分还没做到。

---

1. 引言

大语言模型用反向传播离线训练，训练完就冻住。大脑则一边活一边学：每一刻都在听、想、动，也都在一点点改变。本项目的目标由作者（仓库笔记里称“设计者”）提出：做一个像大脑那样实时学习的人工智能，只用神经元搭成，最终能和人交流、在世界里行动。设计原则：

- **纯神经元**。只有二值神经元和连接：不用符号、列表、查找表，也不为任何具体任务写程序。开发中可以临时用程序代替，但必须写明等价的神经元电路，最终换回神经元。
- **全脑一条局部学习规则、一个统一降权**。不用反向传播，不用全局梯度。
- **一直活着**。对话之间不重置，不睡觉，没有离线训练阶段。
- **只通过肌肉输出**。说话就是动肌肉；模型能听到自己的声音。
- **先有先天连接**。每个区都由同一个生成器在出生时生成，学习在此之上进行。第一代可以手动接一些连接（“第一代连接”），每组都登记在案；后代继承融合后的连接。

本文的贡献：

1. 一份只写规则的架构说明（第 2 节；仓库里 `docs/ARCHITECTURE.md` 是唯一权威版本）。
2. 理论（第 3 节）：
   - 不同前文的编码重叠很小时，最后一层 “接下来是什么” 的赫布读出，等于自回归模型的读出；
   - 必须满足的四个前提，以及一个信噪比公式；
   - 带预测误差的读出就是反向传播在最后一层做的那一步；
   - 时间差的结果，后来正是它决定了模型能学会什么。
3. 严格按规则搭出的大脑的实测（第 4 节）：新生大脑能记住什么、活动能不能保持在范围内、信息丢在哪一层。
4. 一个看功能、看连接权重的测试，而不是靠长时间等结果（第 5 节）：在一门自创的逻辑语言里，大脑听、想、说。
5. 附录：设计者的想法；另一个独立课题，即让反向传播训练出的语言模型用局部规则持续学习。

文中所有数字都来自仓库里的运行，每个都能追到脚本和报告文件。早期用过符号捷径的原型已被这套规则取代，不在本文报告。

2. 架构

2.1 神经元和网络

1. 神经元只有亮和不亮两种状态。抑制神经元就是输出权重为负的普通神经元。
2. 编码是分布式的：一个东西激活很多神经元，没有 “一个字一个神经元”。
3. 输入层用温度计正反对编码：每对恰好亮一个，所以输入层永远一半亮。“什么都没有” 也是一个读数。
4. **每个区都用同一个生成器生成**：立体、局部、随机。
   - 每个神经元只接上一层附近的几个神经元，按 y、z 算远近，出生时的权重固定；
   - 每个神经元的门槛按它自己收到的信号来定，所以相似的输入激活相似的神经元。
5. 感觉区越往后的层亮得越少。前额叶最后一层亮的数量等于输入层，中间层可以多一些（约 30%，见 2.5 节）。
6. 自己和别人的声音激活相似但不同的神经元，不需要标签。

2.2 各区

感觉区：听觉、视觉、触觉（含每块肌肉实际用的力）。

- 视觉中心像素多、边缘少；前几层另有局部运动神经元，出生就连到眼肌。
- **抽象概念区**接收各感觉区的特征神经元，用同一条规则学习。经常一起出现、或上下文相同的东西，编码会变得相近，不变性就这样学出来：在视野中间看到人时，“人” 的概念神经元亮起；人慢慢移到边缘，概念神经元还亮着，就和边缘的神经元连起来。

链式神经元：

- 每个区每一层的特征神经元，都一对一地送到前额叶第一层（副本），也送到海马体；
- 每条去程链配一条回程链，副本亮了会让原来那个神经元亮起；
- 靠近输入、一直亮着的神经元没有特征，不建链。

前额叶：多层循环网络。

- **各层**：第一层是各区的副本；中间各层是同一生成器生成的固定随机局部网络；最后一层这一刻的活动，和下一刻第一层里接着亮的神经元做赫布连接，学 “接下来是什么”；最后一层内部的连接也学习，有关的互相激活。
- **层数**：用够用的最少层数，相当于皮层一列里的 3–4 级。层让最后一层比输入晚一点，也把特征组合起来。两层不够：“NOT T” 的答案是两个特征的异或，需要中间层先组合（第 5 节）。
- **回路**：出生时就有回路，最后一层能反过来点亮第一层，把想法保持住。
- **输出就是第一层被内部点亮**。
  - 点亮的来源有三种：预测、回路、海马体回忆（经感觉区回来）。
  - 被点亮的副本经回程让原来的神经元亮：在感觉区是内心的声音和想象的画面，在运动区就是意图。
  - 回程强度是 “理性和本能” 的旋钮。
- **兴奋度和思考**：兴奋度相当于上下文长度。思考是连续的，不会重开；说话由思考引起，外界只影响思考。
- **工作记忆**有两部分：一是各层的延迟，新生时约 5 拍；二是回路和学到的连接保持住的想法，学过以后能到十几拍。一句话要在这个窗口里说完，前额叶才能把整句和后面的回答连起来（第 5 节）。

海马体：

- 有自己的一群神经元，出生时随机接收各区的副本，内部没有出生回路；
- 内部连接和回忆连接用同一条赫布规则，但长得快、忘得快，每拍亮的数量固定；
- 回忆点亮感觉区里对应的神经元，再间接影响前额叶；
- 什么都存。长期记忆由皮层靠反复回忆慢慢学会。不睡觉，没有时间环。

运动区和说话：只通过肌肉输出。

- **每块肌肉的神经元**：一群力度神经元，亮得越多，力越大；常亮的阻断神经元，管“默认不动”；平时不亮的停止神经元，“说完就停”和前额叶的“让它停”都学到它们身上。
- **说不说是一场竞争**，没有硬门槛：没把握就不说。
- **声音和动作只经前额叶连接**：前额叶最后一层里代表某个声音的神经元 → 第一层里那几块肌肉的力度副本 → 回程 → 力度神经元 → 和阻断神经元竞争。
- **两个先天例外**：
  - 输入层 → 停止神经元的刹车：按附近声音的强弱刹，只能让动作停，只给出“轮流说话”的倾向；
  - 视觉运动 → 眼肌。

杏仁核（先天价值）：

- 自己的一群神经元，出生就接好，对某一类、某一范围的信号起反应；
- 亮了以后给出倾向（靠近、停下、注意），也是奖励信号的来源；
- 可以有多个，比如快乐的、恐惧的。

2.3 学习

- **时序赫布**：
  - B 亮起时 A 刚亮或刚灭，A→B 加强；
  - 一直亮着的 A 碰到 B 亮，不加强；
  - A 在 B 之后自己重新亮起，A→B 减弱；
  - B 熄灭不改变任何连接；
  - 同时亮的不互相加强。
- **第一层副本自己检查对错**（最后一层 → 第一层的连接）：
  - 副本从外面亮了，最后一层却没把它推过“门槛 + 余量 2” → 来自刚才亮着的最后一层神经元的连接加强；
  - 被推过门槛、外面却没来 → 减弱；
  - 已经对了就不变；
  - 每拍的改动（步长 0.3）由连到它、当时亮着的神经元平分。
  - 打砖块里，这条规则让猜对玩家按键的比例从 52%（只在副本刚亮起时学）升到 87%，再升到 92%。
- **凹形增长，没有上限**：$\Delta w = \eta \cdot a_i \cdot a_j / (1 + w/w_{ref})^p$。减弱和降权也按同样的系数变慢，永远保留约 1% 的可塑性。常用的强连接难改，学会了就不容易忘，对应神经科学里的“元可塑性”。
- **全脑一个统一降权**：后天长出的连接定期乘一个系数，太弱的删掉；出生连接不降；海马体降得最快，越深的层降得越慢。
- **时间就是先后顺序**：不需要表示“过了多久”。
- **奖励只是工具**：
  - 做对了加强、做错了削弱最近一两秒里带出动作倾向的连接（最后一层 → 动作的副本），别的连接不动，所以模型仍记得做错的事，但不会再做；
  - 每个动作当时亮着的那一组就是它的选择：按着是“按下组”，不按是“停止组”；
  - 越近的改得越多；难过时，之前因为高兴加强过的也一起削弱；
  - 好坏只来自先天价值，不按回应多少来定；
  - **主要靠听别人说来学，奖惩只是偶尔纠正**：多奖少罚，只在很有把握却答错时才明确惩罚；
  - 记功劳的必须是动作本身，也就是答题那一刻的选择。
- **结构可塑性（很慢）**：总是亮的神经元分裂，从不亮的删掉，判据是能不能区分事物。
- 不为任何现象写专门的机制。

2.4 一生、世界和后代

- **一直活着**：小时候允许犯错，不抢话的先天刹车一直保留。

- **世界一直在教**：大人对“说得接近”也会高兴，这就是奖励。不做跟读训练。
- **训练顺序**：
  1. 第一代在前额叶里手动接好“声音 ↔ 发出它的肌肉”，每组都登记，测“能不能学会”时只用从没手动接过的内容；
  2. 再让模型听大量别人之间的对话；
  3. 想到回答，就会自动说出来。
- **进化**：随机生成 → 考试 → 留种 → 繁殖。
  - 孩子的每个数字 40% 随父、40% 随母、20% 取两者平均，再随机改一点；
  - 后代带着融合后的连接出生，还要重新学，但学得更快；
  - 价值观是先天的，不参与融合。
- 放大时全脑一起放大。最终成品是纯神经元。

2.5 实测定下的实现细节

- **前额叶中间层约 30% 亮**。太稀疏时每个神经元太挑剔，同一句话换个声音就被拆散：用第 4 种声音认 60 句话，最后一层的正确率在中间层亮 2.6% 时是 0.06，10% 时 0.21，30% 时 0.41，50% 时 0.42。
- **想法的数量**：
  - 上限按“平时”的外部输入量算，不按这一拍的，否则安静时名额为零，想法点不亮；
  - 想法名额只给此刻外面没亮的副本；
  - 想法不是越多越好：学过的大脑在名额为平时输入量 10% 时记得最长，100% 时反而记不住。
- **最后一层内部连接的上限**：内部学到的连接给一个神经元的总推动，不超过出生时输入推动在各神经元间的差别（约 1.6）。否则练久了内部推动是输入的上千倍，状态不再由听到的决定。
- **第一代连接的存法**：按“用熟了”的强度存，日常学习就冲不掉。它仍用时序赫布，不用自我检查，否则“想到一个音却没说出口”会把它削弱。
- **自我检查的两个条件**：加强一直到推动超过门槛 2 才停；减弱只在真被推过门槛、外面却没来时才做。

2.6 不要用的东西

- 反向传播、全局梯度；
- 让神经元给自己加分保持亮；
- 用不应期推动想法；
- “后亮的抑制先亮的”；
- 时间环、时间细胞；
- 一个字一个神经元、编号、列表、记录表；
- PMI 闸门、枢纽抑制、除法增益、出生偏置之类的补丁；
- 单独的误差修正读出层、单独的基底节或价值模块；
- 照着测试世界写的反射和开关；
- 按回应多少定奖励。

3. 理论

3.1 正式定义

每一拍所有神经元非 0 即 1。x_t 是各区所有特征神经元的副本。前额叶：

- 第一层 L1_t = x_t ∨ y_t。
  - y_t 是想法：y_t = [d_t − u_t > θ] ∧ top_m(d_t − u_t)，其中 d_t = G·a_{t−1} + W·a_{t−1}；
  - G 是出生时固定的回路，W 是学到的“最后一层 → 第一层”读出，u 是每个副本的“平时水平”；
  - m = κ·n̄，κ 是兴奋度，n̄ 是平时的外部输入数量。
- 中间层：L2_t = [F_2·L1_{t−1} > θ_2]，L3_t = [F_3·L2_{t−1} > θ_3]。F 是固定的局部随机网络：每个神经元接附近 K 个输入，权重在 U(0.5, 1.5) 中随机取，门槛定成亮的比例为 ρ_mid。
- 最后一层：a_t = top_{|L1_{t−1}|}(F_4·L3_{t−1} + g·V·a_{t−1} − u^4_t)。V 是最后一层内部学到的连接，有上限。
- W 和 V 用同一条局部规则学习，凹形系数 φ(w) = 1/(1+w)，所有学到的连接一起定期降权。
- 海马体：s_t = top_{k_h}(R·H1_{t−1} + U·s_{t−1} − u^s)，回忆 h_t = top_m(Q·s_{t−1} − u^h)，H1_t = x_t ∨ h_t。

- 想法和回忆经回程点亮来源：内心的声音、想象的画面、打算的动作。说话就是前额叶预测出下一刻的肌肉力度。

3.2 前额叶和语言模型做的是同一件事

- **两边的结构相同**：
  - 自回归模型把前文压成状态 h_t = F(x_t, h_{t−1})，读出 W·h_t，把最可能的下一个输入再喂回去；
  - 这里最后一层 a_t 是状态（当前输入经 F_4，加上 V·a_{t−1} 带进前文），W 是读出，推动最大的副本作为想法成为下一刻的输入；
  - 两边都是 “状态 → 预测下一个输入 → 当作输入”。
- **读出相同**：
  - 若不同前文 c 在最后一层用的神经元互不重叠（各自一组 S_c），推向副本 j 的力 = |S_c| ×（前文 c 之后 j 出现的次数），推得最大的就是 c 之后最常见的下一个输入，正是训练到最好的语言模型的输出；
  - 矩阵形式 $W = \Sigma\, x_{t+1} \cdot h_t^{T}$，在 h 互相正交时与最小二乘解 $Y \cdot H^{T} \cdot (H \cdot H^{T})^{-1}$ 只差一个比例，后者正是反向传播在最后一层收敛到的解；
  - 中间层固定随机就足以把不同前文分开（Cover 定理；回声状态网络、液体状态机）。

四个前提必须成立：

1. **不同前文在最后一层的重叠要小**：重叠越大，读出越像 “不看前文、只说最常见的”。
2. **连接强度跟出现频率成比例**，而不是无限累积（统一降权）。
3. **推动最大的那些能真正亮成想法**：名额按平时输入量算。
4. **最后一层主要由最近的输入决定**（回声状态性质）：同一个 A 每次出现，要用差不多同一批神经元。内部连接不设上限就会破坏这一条：练 3 千段时内部推动是输入的 12 倍，7.9 万段时超过上千倍，所以要给内部连接设上限。

信噪比：一对搭配 A→B 对比竞争者 X：

信噪比 = (n(A,B) − n(A,X))(1 − o) / sqrt((var_B + var_X)/K_p)

其中 o 是不同前文在最后一层的重叠，K_p 是一个副本收到的最后一层亮神经元数。语料最常见的 20 对搭配：

大脑	重叠 o	K_p	信噪比中位数	可靠（信噪比 > 3）的对数
大号，新生	0.19	79	2.4	5 / 20
大号，练过	0.10	98	3.9	14 / 20
小号，新生	0.16	17	1.2	0 / 20

信噪比和练多久无关，只由编码决定：干扰来自重叠。

计数和预测误差：

- **只计数的读出**：等于一个以编码重叠为核的二元组平滑；核太平时它不看前文。300 个常见音节，每个由 3 种声音各念 6 遍，计数读出预测下一个音节 11.6%，和不看前文（11.1%）一样，听多少遍都不变。
- **带预测误差的读出**（没预测到却来了就加强，预测了却没来就减弱）：这恰好是输出层的随机梯度下降，也就是反向传播的最后一步。它收敛到岭回归，降权够强时达到 31–32%。第一层副本的自我检查就是这条规则。

信息丢在哪：

- 耳朵的输入位按类均值能认出 81% 的音节，经过 4 层越来越稀疏的固定随机听觉层后只剩 38%；
- 无标签的赢者通吃原型（带 “赢太多就让一让” 的局部项）用 300、600、1,200 个单元能恢复 19%、25%、30%；
- 让音节之间的差别超过音节自身变化的方向，只有约 10 个。

时间差：一个音节持续 3 拍。最后一层认出刚听到的音节：

音节开始后第几拍	4	5	6	7
认对	40–43%	49–55%	48–52%	28–35%

信号要 4 拍才到最后一层，所以下一个音节刚开始时，“上一拍的最后一层 → 这一拍亮的副本” 这条连接还看不到上一个音节。在合适的时刻读下一个音节：听过的句子原顺序 10.9%，打乱 7.2%；没听过的 9.2% 对 4.9%；知道当前音节、数过相邻对的理想读者是 20.8%。后来正是这个时间差，决定了模型能学会什么（5.4 节）。

4. 按规则搭出的大脑

4.1 新生大脑

严格按规则搭出的整脑：各区共用一个放大倍数，链一对一，前额叶各层进多少出多少、回路闭合，运动区只靠竞争。还没学习时：

- **能把问题记过一段安静**：
  - 安静 12 拍后，听到的问题仍能认出：32 选 1，问题刚结束 1.00，6 拍后 0.64–0.71，12 拍后 0.34–0.40（瞎猜 0.03）；
  - 条件是每小块有一个不学习的局部抑制神经元，回路“互相对应”（每个最后一层神经元回到通往它的路径权重最大的那些副本），回路强度 1.0；
  - 随机接的回路，12 拍后不超过 0.16。
- **各层数量守恒**：相邻层亮的数量之比 0.90–1.05，安静和说话时都一样。没有局部抑制、回路又强时，前额叶会全亮（95%）或冻住。
- **活动为什么上涨**：学习时活动上涨，只来自最后一层内部连接和海马体内部连接学到的强度，这两个定为 0.1。
- **语音大脑（34 个音）**：前额叶各层都能分清换了声音的音（第 1–3 层 1.00，最后一层 0.97）；听到的问题，刚结束时 0.66，6 拍后 0.31，12 拍后 0.13。

4.2 学习：留住什么、丢了什么

- **海马体**：
  - 规则是“每跟着出现一次加一整步”，推动等于连接总和，忘得快（2 万个神经元，每拍亮 50 个）；
  - 新句子只听一次，推向下一个音节的力是其他音节的 1.5–2 倍，过约 3 段对话就忘了，这就是短期记忆；
  - 去掉出生回路、只靠快速变化的权重时：同一输入回到同一编码 0.85–1.00；问题隔着停顿连到答案 0.94–1.00；普通句子听一次能接出后面 0.84–0.90；
  - 开头一样的两段经历分不开（0.45–0.56），所以“我的 X 叫……” 这类一次性事实只有 0.25–0.54。
- **长时间旁听**（RTX 4090，每拍 7 毫秒，5,000 段对话约 25 分钟）：
  - 活动一直稳定；
  - 清空海马体后，前额叶对正确答案的排名只从 11.5 退到 12.5，说明前额叶学到的东西存在它自己的连接里（皮层的长期记忆）；
  - 海马体内部连接强度 0.1 时，2,000 段后会卡住，0.01 时不会。
- **规律性**：
  - 从同一个大脑状态出发，同一句话亮同一批神经元：想法重合 0.61–0.72，最后一层 0.78–0.86；不同句子分别是 0.15 和 0.25–0.28；
  - 换声音时想法的一致性，从新生的 0.17–0.23 升到听过 6.9 万段后的 0.49–0.51；
  - 但隔一段时间再听，最后一层的状态完全不同（0.00），而输入（0.50）和中间层（0.65–0.81）都稳定；
  - 把最后一层的内部连接设为 0 就恢复（0.53）；听之前安静 15 拍以上也稳定（0.58–0.69）；
  - 原因：内部连接把刚听到的内容“抓住” 约 10 拍，而对话中两轮之间只隔 4–10 拍，每句话都被上一句盖住。
- **大语料**：
  - 660 万段中文对话（LCCC），转成带声调的音节，由 4 种合成声音念出；
  - 旁听 1,000 段后，前额叶预测下一个音节仍是瞎猜水平，计数模型已能猜对 14%，活动正常；

- 原因可能和 5.4 节找到的一样：说话节奏不合前额叶的窗口，整句就连不到后面。这一点还没有在大语料上验证。

5. 一门自创的逻辑语言：听、想、说

5.1 设置

不用人类语言，而是一门自创的小语言：

- **词**：13 个词（T、F；NOT、AND、OR、SAME、IS；名字 A–D；“.” 和 “?”），加两个答案词 YES、NO。
- **怎么呈现**：每个词是屏幕上一个固定的随机图案，由视觉区看到。
- **五个阶段**：每个阶段加新句子，旧句子继续出现。

阶段	句子	要会的
1	T ?、F ?	真假词
2	NOT T ?	否定
3	T AND F ?、F OR T ?	两个值组合
4	A SAME B ?	记住第一个名字再比较
5	A IS T . A ?	把名字绑定到值，之后再问

- **怎么回答**：用 YES、NO 两块肌肉。每块肌肉有自己的按下组和停止组（抑制），“都不动”“动一块”“两块都动” 都是输出；只有准确激活对的那块肌肉才算对。
- **答案平衡**：每类句子的答案 YES、NO 各占一半，否则 “AND 总答 NO” 就能对 75%。
- **大脑大小**：最早的几组用 12×16 的屏（2,311 个副本），后面换成 4 倍大的大脑（24×32 屏，9,372 个副本）；没特别说明时，前额叶都是 4 层。

5.2 只靠奖惩，参数从连接权重算

算出来的参数：功劳只记答题那一刻的选择、而且全额记。这样一次奖惩，会让同一个输入的推动改变约 3.6 × 步长；步长 0.5 时约为运动噪声的两倍，错一次下一次就会改。

- 沿用早先游戏测试的参数（步长 0.06、记录 15 帧、按意外程度记功劳）：1,000 句都没学会第 1 阶段；
- 用算出来的参数：40–100 句就学会了。

层数的影响：两层的前额叶学会第 1 阶段要 239–352 句，第 2 阶段学不会；四层的学会第 1 阶段要 73 句，第 2 阶段 762 句。答题那一刻能从最后一层读出多少答案（新生小号大脑，1.0 = 完全能读出，0.5 = 瞎猜），说明了原因：

前额叶	阶段 1	2	3	4	5
两层	0.88	0.56	–	–	–
三层，回路 ×2	0.99	1.00	0.73	0.82	0.81
四层	1.00	1.00	0.85	0.48	0.92
四层，回路 ×2	1.00	1.00	0.97	0.90	0.98

后续改进和瓶颈：

- 运动噪声减半、学奖励时前额叶自己的连接不动，学会第 2 阶段从 1,981 句缩短到 138 句；
- 4 倍大的大脑加上回路 ×2，第一次学完了全部 5 个阶段（第 3,263 句学会第 5 阶段，约 5 分钟计算）；
- 但所有阶段混在一起时，答对率一直停在 60–75%：
  - 去掉噪声看每类句子的推动，发现它学的是捷径：“AND 总答 NO”“OR 总答 YES”，SAME 和 IS 接近瞎猜；
  - 可训练后的最后一层，用一个读出仍能分开所有答案（0.92–0.94）；
  - 奖励连接已经长到平均 3（最大 15），只剩约 30% 的可塑性。

5.3 照架构的顺序：先听

按第 2 节的训练顺序，大脑只听别人之间的对话（“T ? YES”“NOT T ? NO”……），肌肉不动，没有任何奖惩，前额叶照常学 “接下来是什么”。测试时不学习，看答案词出现前它预期哪个词：对 YES 词副本的推动对比 NO 词副本，以及哪个词的副本占了想法名额。

- **第 1 阶段**：听 20 段对话后预期 100% 正确（步长 0.3；步长 1、3、10 都不更快，而且更不稳）。
- **说出来**，用三组固定连接，全部登记：
  - 第一代 “词 ↔ 肌肉”：答案词的副本被内部点亮（是想到，不是听到）时，推它那块肌肉的按下组；
  - 常亮的阻断神经元让肌肉默认不动；
  - 先天刹车按输入层亮的格子数，推两块肌肉的停止组，并能撑过两个词之间的空隙。
- **参数从测到的数算**：听过对话的大脑在轮到自己时，每拍约有 11 个副本想到对的词，4.4 个想到错的词，总名额 35 个。连接强度就由这些数算出。
- **一生的安排**：一半时间听别人问答，一半时间轮到它答；它说的词以更轻的 “自己的声音” 出现在屏幕上。

第 1 阶段，约 500 轮	抢别人话	跟着别人说	轮到它时开口	开口时答对
新生大脑，不奖惩	0%	0%	80%	75%
听过对话，不奖惩	0%	0%	40%	99%
听过对话，偶尔纠正	7%	0%	83%	96%

- **轮流说话**：这个倾向由固定连接给出，正如设计。
- **完全不纠正**：跑 1 万轮（其中 5,000 轮轮到它答）后，答对率掉到 50–65%。它听到自己说错的话，也当成 “接下来是什么” 学了进去。
- **偶尔纠正**（答对奖励，只在很有把握却答错时惩罚）：学会了否定和 AND/OR（第 2 阶段在 2,734–7,500 轮，第 3 阶段在 14,962 轮，其中一半是它自己答的）。但学得慢，而且越来越急着回答，常常在别人回答之前就抢答别人的问题。

5.4 说话节奏要落在工作记忆窗口里

一开始学会的是捷径：只靠听时，大脑先学成了 “有 NOT 就反着答”，普通句子反而答错。原因不在规则。

怎么查：把一个不学习的大脑在答案词出现前一刻的最后一层录下来，再让副本自我检查规则在这些固定状态上学，这样就单独测出了问题在哪：

- **说得慢**（每个词 3 帧，再空 1 帧）：答题时 NOT 已经离开最后一层，“T ?” 和 “NOT T ?” 几乎是同一批神经元。学 60 遍，四句话从没有全部学会，换成可正可负的连接也一样；不管回路强 1–4 倍、兴奋度 10–100%，还是两段对话之间安静多久都一样。
- **说得快又马上答**：T 还没传到最后一层。
- **每个词 1 帧、不留空、问完停 3 帧再答**：“T ?” 亮 52 个、“NOT T ?” 亮 44 个，各自独有 43 个和 35 个，数量相近、内容不同。用原来的规则、只有兴奋性连接，**四句话 1–2 遍就全学会**。

按这个节奏真实地边听边学：

- 第 1、2 阶段都到 1.00，预期的词和想到的词都对；
- 5 个阶段混在一起听 3,000 段后：第 1 阶段约 1.00，第 2 阶段 0.83–1.00，第 3 阶段 0.56–0.94；第 4、5 阶段的句子有 4 个和 6 个词，比窗口长，还在瞎猜附近。

记忆曲线：说完 “NOT T” 后，最后一层还能分辨刚才有没有 NOT 的时长：

大脑	能稳定记住到第几拍
新生，出生回路	5
新生，回路 ×2	7
新生，中间层只亮 10%	7（回路 ×2 时到第 14 拍仍有 0.6–0.9）
按合适节奏听过 3,000 段	13

- **窗口会变长**：新生时主要靠层的延迟，学过以后学到的连接把想法保持住，能到十几拍。
- **想法不能太多**：兴奋度 100%、每拍 195 个想法时反而乱。

- **中间层稀疏的取舍**：更稀疏时记得更久，但换个声音认句子的能力变差（2.5 节）；中间层 10% 时，3 个词以内的句子略好，更长的句子都没学会，所以暂时保留 30%。

5.5 读出它在想什么

每一拍，读出“自己的副本占想法最多的那个词”：

- **只听过第 1 阶段的大脑**：
  - 给它看 “T ?” 然后什么都不给，下一拍它就想到 YES（占想法的 36–38%）；
  - 看了 “F ?” 后一直想着 NO（40–68%）；
  - 只看 “T”，3–4 拍后它会自己把 YES 接上。
- **听过所有阶段的大脑**：想法会落到 YES 上。在这门语言里只有答案词是能确定预测的；NOT 后面接 T 还是 F 本来就随机，所以那里想不出清楚的词。
- **要想出新句子**：思考里需要一点随机性，就像肌肉有运动噪声一样。

6. 讨论

这个大脑做得好的：

- 用局部规则实时地从连续的输入里学习，活动保持在范围内；
- 新生时就能把问题记过一段安静；
- 在自创语言里，只靠听，几十段对话就学会（节奏合适时 1–2 遍），并且轮到自己才开口、不抢别人的话，全程不需要任何奖惩。

不只适用于这个测试的经验：

1. **看连接权重，不要等**：每个关键发现都来自直接看权重和状态，包括各层能读出多少、每类输入的推动、一次事件改变多少、记忆曲线、想法。
2. **一句话必须落在工作记忆窗口里**：学组合就是学一句更长的话；开头已经淡掉、或结尾还没到，就学不会。大语料如果按别的节奏说，可能只因为这一点就学不会。
3. **功劳要记在动作本身上**：只全额记答题那一刻的选择，错一次就能改；用长记录、按意外程度记功劳，则完全学不会。
4. **主要靠听，偶尔纠正**：从别人那里学 “接下来是什么” 会学到对的答案；能听到自己的大脑也会学到自己的错，除非世界偶尔纠正它。
5. **参数可以从权重算出来**：步长由一次事件引起的推动变化算出，连接强度由测到的想法数量算出，不必靠搜索。

7. 局限和下一步

局限：语言的大部分还没做到。

- 比窗口长的句子（第 4、5 阶段）还学不会；
- 自然语料还没学到超过瞎猜；
- 只用两块肌肉回答；
- 海马体还没解决一次性事实，以及开头相同的经历怎么分开；
- 概念区和结构可塑性还没放进测试的大脑。

下一步：

1. 让更长的句子落进窗口：靠学习保持想法、说话节奏、回路；
2. 给每个词接一块肌肉，让大脑能说出整句；
3. 给思考加随机性，统计它自己想出的句子有多少合语法、真假对；
4. 然后用文本数据集训练（每个字一个图案，对话按第 5 节的方式）；
5. 全脑一起放大；
6. 让学会逻辑的大脑有目的地在世界里行动。

致谢

架构和原则由作者提出。代码、实验、分析和本文文字由 AI 系统（Anthropic 的 Claude）在作者指导和检查下协助完成，作者对内容负全部责任。

附录 A　设计者的想法（与现架构一致的部分）

1. **前额叶和大语言模型做的是同一件事**：顶层状态预测下一个输入，预测出来的再当作输入。赫布学习在本地、实时地做这件事（改一根连接，学一次就生效）；反向传播要改整个网络，只能离线做。
2. **用回路保持想法**：激活 A 后激活了 G，G 也能返回来继续激活 A。
3. **感觉区和运动区就是前额叶的输入和输出**。
4. **局部连接**：神经元只连上一层附近的神经元。
5. **随机网络 + 赫布连接**：不必规定中间层亮哪些，相似的输入激活相似的神经元。像婴儿那样，先长出很多随机连接，再在上面学习和修剪。
6. **说话由思考引起**，外界只影响思考。
7. **总想到同一件事是特性，不是 bug**，强弱可以调。
8. **一直活着**，不是对话框；思考是连续的；不需要睡眠：常回忆的事会在皮层形成牢固的连接。
9. **放大要全脑一起放大**，不能只放大一部分。
10. **在仿真世界里让很多大脑一起生活**。
11. **神经元信号有容错**，错几个神经元仍是那个想法；纠正听错字的能力，要在有噪声的生活中练出来。
12. **前额叶兴奋度相当于上下文长度**。
13. **视觉只知道哪些像、哪些不像**，画面代表什么要靠语言来教。
14. **去中心化**：
    - 每个机器人都是独立的个体，在自己的硬件上，靠自己的经历学习，本能上对人类好；
    - 本能是更难改变、读宽泛特征、给出宽泛倾向的连接；
    - 价值稳定，选择自由，“不伤害人”强于“帮忙”；
    - 无法保证每一个个体都好，但多样的个体组成的社会是稳定的。
15. **繁衍**：随机生成 → 考试 → 留种 → 按 40/40/20 繁殖再随机改一点；后代带着融合后的连接出生，重新学，学得更快。
16. **小时候允许犯错**，只保留“别人说话时不抢话”的先天刹车。
17. **最终成品必须是纯神经元**。
18. **常用的强连接更难改变**，向上向下都难：学会了就一辈子不忘。
19. **独处时自己思考，回忆有用的事**；思考范围要宽，不被外界轻易打断。海马体什么都存，凹形增长让天天重复的东西不会越存越多。
20. **时间就是先后顺序**，不需要表示“过了多久”。好坏只来自先天价值。
21. **2026 年 11 月的补充**：
    - 前额叶用够用的最少层数（皮层的 3–4 级）；
    - 前额叶也能听几遍就记住；
    - 主要靠听，奖惩只是偶尔纠正；
    - 轮流说话只是一种倾向，由听到别人声音时推高的抑制神经元给出；
    - 组合逻辑本质上就是一句更长的话。

附录 B　独立课题：用局部规则让反向传播训练出的语言模型持续学习

这个课题和本大脑架构无关（仓库 `side/llm2hebb`）。

- **能精确转换的部分**：训练好的模型，前向计算能精确转换。学习规则只在本来就等于反向传播的地方能精确转换，即输出层的 delta 规则，以及“固定预测”的预测编码（每层与真梯度余弦 1.000）。
- **便宜的局部规则离梯度很远**：逐层局部 delta 约 0.20，反馈对齐约 0，标准预测编码直接发散。
- **“局部”本身不能消除遗忘**：与梯度一致的局部规则，遗忘和反向传播一模一样。
- **RWKV-7 的记忆状态就是 delta 规则（赫布）记忆**：
  - 一次就记住，但只能保持几百到上千个词元；
  - 一直不重置，1.6–3.2 万词元后状态会漂移，到 100 万词元时交叉熵从 3.9 升到 9.9；
  - 放大到 15 亿参数也一样。
- **用秩一赫布更新往 MLP 里一条条写事实**：约 30 条后就互相覆盖。
- **成功的做法**：

  - 在冻结的网络旁边放一个独立的情节记忆，用人名的稀疏码做钥匙（像海马体齿状回）：1 万条事实一次学会，不遗忘；换说法问 0.99，问答格式 0.76，不会串到别人身上，不会误触发；
  - 交错回放进权重（同时复习旧事实、混入普通文本）：去掉记忆库后仍记住 2,000 条中的 98%。
- **结论**：持续学习需要冻结继承的网络 + 快权重工作记忆 + 按实体做钥匙的稀疏海马式记忆 + 交错回放，正是“海马体快记、皮层慢学”的分工。

附录 C　复现

- **文档**：
  - 规则：`docs/ARCHITECTURE.md`；
  - 理论：`docs/THEORY.md`、`docs/THEORY_fable.md`、`docs/EQUIVALENCE.md`；
  - 测试：`docs/LOGIC.md`。
- **大脑**：`core/`
  - `net.py`：神经元、唯一的生成器、学到的连接、规则和降权；
  - `brain.py`：各区、链、可设层数的前额叶、海马体、运动区、奖励；
  - `gen0.py`：第一代连接；
  - `config.py`：全部参数；
  - `life.py`、`check.py`。
- **逻辑语言**：`theory/logic/`
  - `world.py`：语言、阶段、对话、节奏设置；
  - `life.py`：出生和一生（听、说、奖惩）；
  - `listen.py`：只听的测试；
  - `think.py`：读出想法。
  - 用的是游戏大脑的视觉区和副本：`theory/game/game_brain.py`。
- **硬件**：一张 NVIDIA A100 40GB，numpy 和 PyTorch。3,000 段对话的一生只需要几分钟。

参考文献

- Abraham, W. C. & Bear, M. F. (1996). Metaplasticity: the plasticity of synaptic plasticity. Trends in Neurosciences 19(4).
- Benna, M. K. & Fusi, S. (2016). Computational principles of synaptic memory consolidation. Nature Neuroscience 19(12).
- Cover, T. M. (1965). Geometrical and statistical properties of systems of linear inequalities with applications in pattern recognition. IEEE Trans. Electronic Computers EC-14(3).
- Douglas, R. J. & Martin, K. A. C. (2004). Neuronal circuits of the neocortex. Annual Review of Neuroscience 27.
- Fusi, S., Drew, P. J. & Abbott, L. F. (2005). Cascade models of synaptically stored memories. Neuron 45(4).
- Goldman-Rakic, P. S. (1995). Cellular basis of working memory. Neuron 14(3).
- Hebb, D. O. (1949). The Organization of Behavior. Wiley.
- Jaeger, H. (2001). The “echo state” approach to analysing and training recurrent neural networks. GMD Report 148.
- Maass, W., Natschläger, T. & Markram, H. (2002). Real-time computing without stable states. Neural Computation 14(11).
- Yang, G., Pan, F. & Gan, W.-B. (2009). Stably maintained dendritic spines are associated with lifelong memories. Nature 462(7275).